



UNIVERSIDADE FEDERAL DO RIO DE JANEIRO
INSTITUTO DE COMPUTAÇÃO

Modelagem Cadeia de Markov do
Jogo Snakes and Ladders

Nicholas de Araujo Figueira (121088218)


2025

1. Introdução

Este projeto tem como foco a modelagem computacional do jogo clássico "Cobras e Escadas" ([Snakes and Ladders](#)) com base em Cadeias de Markov de estado finito. O objetivo central não é apenas a simulação do jogo, mas a análise profunda de suas propriedades matemáticas. Especificamente, o trabalho visa:

1. Construir a Matriz de Probabilidades de Transição (Transition Probability Matrix - TPM) que representa todas as regras e movimentos possíveis;
2. Modelar o tempo esperado de jogo como um sistema linear, determinando o número médio de jogadas necessárias para vencer a partir de qualquer casa;
3. Analisar a evolução temporal e probabilística do jogo utilizando técnicas de autovalores e potências de matrizes;
4. Agrupar um conjunto de partidas realizadas com base no algoritmo do Principal Component Analysis ([PCA](#)) e [K-means](#) clustering.

O tabuleiro utilizado segue o padrão de 100 casas, onde a movimentação é ditada por um dado de 6 faces e influenciada por regras determinísticas de salto (cobras que fazem descer e escadas que fazem subir). Ao chegar na casa 100, a partida é encerrada. O tabuleiro usado como base é:



Com a distribuição de escadas e cobras, baseadas no par (origem, destino):

Escadas: (1-38), (4-14), (8-30), (21-42), (28-76), (50-67), (71-92), (80-99).

Cobras: (32-10), (36-6), (48-26), (62-18), (88-24), (95-56), (97-78).

2. Metodologia

A implementação do projeto foi realizada em Python, utilizando as bibliotecas NumPy e SciPy para a álgebra linear numérica, e Scikit-Learn para a análise de dados simulados. O desenvolvimento foi dividido em três etapas principais:

2.1. Construção do Modelo (Matriz de Transição)

O núcleo do projeto é a matriz P de dimensão 100×100 . Esta matriz é altamente esparsa, pois, a partir de qualquer casa i , existem no máximo 6 destinos possíveis (resultado do dado), exceto nas casas que iniciam uma cobra ou escada, onde a transição é determinística para o destino do salto.

- A última casa (100) foi modelada como um Estado Absorvente, onde $P_{100,100} = 1$ indica o fim do jogo.

2.2. Solução do Tempo Médio (Sistema Linear)

Para calcular o vetor de tempos médios de absorção (e), onde cada elemento e_i representa as jogadas restantes a partir da casa i , utiliza-se a equação fundamental baseada na submatriz Q (apenas estados não finais):

$$(I - Q)e = 1$$

O sistema linear foi resolvido utilizando fatoração LU, garantindo estabilidade numérica para encontrar o vetor e .

2.3. Análise Espectral (Autovalores)

Para compreender a velocidade de convergência do jogo (quão rápido o sistema esquece a condição inicial e termina), analisa-se o espectro de autovalores da submatriz transiente Q . Os autovalores λ são as raízes de $\det(Q - \lambda I) = 0$. O autovalor

de maior magnitude (λ_{dom} ou λ_2 no contexto da matriz global P) dita a taxa de decaimento da probabilidade de o jogo continuar.

$$\text{Taxa de Convergência} \approx |\lambda_{dom}|^k$$

Quanto mais próximo de 1 for $|\lambda_{dom}|$, mais lento é o jogo e maior a influência de ciclos (cobras) que prendem o jogador.

2.4. Simulação

Além da solução exata, realizou-se uma simulação de [Monte Carlo](#), através da execução de várias partidas, para gerar dados estatísticos. Aplicou-se PCA para redução de dimensionalidade e K-Means para agrupar as partidas em perfis de comportamento (clusters), permitindo visualizar padrões estocásticos que a solução analítica sozinha não revela.


3. Resultados

Os resultados foram visualizados através de três gráficos distintos que explicam a dinâmica do jogo:

3.1. Visualização da Matriz Esparsa

Este gráfico exibe a estrutura interna da matriz de transição P.


- A Banda Diagonal: Representa o movimento padrão do dado (andar de 1 a 6 casas).
- Os "buracos": As falhas na diagonal indicam as casas de origem de cobras ou escadas. Como o jogador é imediatamente transportado, a probabilidade de permanecer ou terminar o turno nessas casas é zero.
- Pontos Dispersos: Representam os destinos dos saltos. Pontos à direita da diagonal são escadas (avanço) e à esquerda são cobras (retrocesso).



3.2. Mapa de Calor de Dificuldade (Heatmap)

Este gráfico projeta o vetor de tempos esperados (e) sobre o grid do tabuleiro.


- **Cores Claras (Valores Altos):** As cores claras indicam um número elevado de jogadas restantes. Isso ocorre em dois cenários:
 1. **Distância Física:** As casas iniciais (1, 2, 3...) aparecem claras/quentes porque estão longe do objetivo. É natural que faltem muitas jogadas no início.
 2. **Armadilhas Estatísticas:** Estas são as zonas de "gargalo" do tabuleiro, geralmente localizadas antes de grandes cobras, onde o jogador estatisticamente tende a ficar preso por mais tempo.
- **Cores Escuras (Valores Baixos):** Representam valores baixos de e . Indicam proximidade da vitória (ex: casas 94-99), onde a matemática mostra que poucas jogadas são necessárias.



3.4. Espectro de Autovalores

Ao plotar os autovalores da matriz Q no plano complexo, identificamos o Autovalor Dominante (λ_{dom}).

A maioria dos autovalores agrupa-se perto da origem (transições rápidas). Um pequeno grupo de autovalores se destaca próximo à borda do círculo unitário. O valor de $|\lambda_{dom}|$ (magnitude do segundo maior autovalor) atua como o "fator de amortecimento" do jogo. Logo, se $|\lambda_{dom}| \approx 0.95$, isso indica que a cada rodada, "sobra" 95% da probabilidade do jogo continuar (em uma análise assintótica). Cobras longas perto do final (como a 97 e 95) são as responsáveis por "empurrar" esse autovalor para perto de 1, esticando a duração do jogo.



3.5. Clusterização de Partidas (PCA + K-Means)


A análise de ML gerou uma nuvem de pontos onde cada ponto é uma partida completa.

O que são os Eixos (PC1 e PC2)?

- **PC1 (Eixo X - Variância Principal):** Geralmente representa a "eficiência da partida". Valores em um extremo indicam jogos onde o jogador avançou consistentemente (pegou escadas), enquanto o outro extremo indica jogos onde o jogador ficou preso em ciclos (caindo em cobras repetidamente). É o eixo que mais separa os jogos curtos dos longos.
- **PC2 (Eixo Y - Variância Secundária):** Representa a "forma do jogo". Dois jogos podem ter a mesma duração, mas formas diferentes (um ficou preso no início, outro ficou preso no final). O PC2 captura essas nuances estruturais de onde o jogador passou mais tempo.

O que significam as cores (Clusters)?

- **Cluster roxo:** Pode representar os "jogos rápidos". São partidas com poucas jogadas, onde o vetor de ocupação mostra que o jogador quase não pisou em casas "ruins" e aproveitou atalhos.
- **Cluster amarelo:** Representa os "jogos demorados". Partidas longas, com alto número de movimentos, caracterizadas por alta ocupação nas casas que levam a cobras (como a casa 97 ou 88).
- **Cluster azul:** O comportamento médio, representando a experiência padrão do jogo sem extremos de sorte ou azar.



4. Análise dos Resultados

A modelagem confirmou que Snakes and Ladders é um processo markoviano clássico: o sistema não tem memória; a probabilidade de ir para a casa 50 depende apenas de estar na casa 45, e não de como você chegou lá. A resolução do sistema linear demonstrou-se uma ferramenta $(I - Q)e = 1$ poderosa. Enquanto uma simulação de Monte Carlo nos dá uma aproximação da média após mil jogos, a álgebra linear nos fornece o valor exato em uma fração de segundo. Isso valida a importância da modelagem matricial em problemas estocásticos.

Ao decompor a matriz, identificou-se um autovalor dominante (λ_{dom}) com magnitude 0.95. Este valor atua como o "fator de decaimento" do sistema. Em termos físicos, ele indica que, a cada rodada do jogo, cerca de 95% da probabilidade de a partida continuar permanece no sistema, enquanto apenas uma pequena fração "escapa" para o estado final.

A visualização do espectro no plano complexo evidenciou que este autovalor é "empurrado" para perto de 1.0 devido à presença de cobras longas próximas ao final do tabuleiro, especificamente as cobras (97, 78) e (95, 56). Estas estruturas funcionam como barreiras probabilísticas ou "gargalos", que aprisionam o jogador em ciclos, retardando drasticamente a convergência do sistema para o estado estacionário.

A aplicação de PCA e K-Means sobre os dados simulados corroborou a análise matemática. O algoritmo foi capaz de segmentar as partidas em clusters distintos de comportamento sem conhecimento prévio das regras. O agrupamento revelou que a sorte ou azar não são aleatórios, mas estruturais: o cluster de "jogos longos" apresentou alta correlação com a ocupação das casas que antecedem as cobras críticas identificadas na análise de autovalores.

5. Melhorias Futuras

Para expandir este projeto e explorar novas fronteiras matemáticas, sugerem-se as seguintes melhorias:

5.1 Análise de Sensibilidade (Perturbação da Matriz):

Modificar o código para remover uma cobra ou escada por vez e recalcular o vetor e . Isso permitiria criar um "Ranking de Importância", identificando matematicamente qual é a cobra mais devastadora ou a escada mais valiosa do jogo.

5.2 Alteração das Condições de Contorno (Bounce-back)

Implementar a regra onde o jogador deve tirar o número exato para entrar na casa 100, caso contrário, ele avança e volta. Isso eliminaria a simplificação atual e

tornaria a submatriz próxima ao estado n tridiagonal, aumentando drasticamente o tempo esperado de término.

5.3 Comparação de Convergência (Autovalores)

Calcular explicitamente os autovalores de Q para diferentes configurações de tabuleiro. Plotar o espectro de autovalores no plano complexo para visualizar como a "estabilidade" do jogo muda com a adição de mais cobras

6. Conclusão

Em suma, o projeto mostrou que:

1. Existe uma correlação direta entre a posição das cobras no tabuleiro e a complexidade computacional/temporal da partida.
2. A matriz de transição P capturou com fidelidade a física do jogo. A capacidade de calcular tempos médios exatos via fatoração LU provou que métodos analíticos são preferíveis a métodos estocásticos (simulação) quando o espaço de estados é finito e conhecido.
3. Ferramentas de aprendizado de máquina são capazes de identificar "tipos de sorte" (clusters) sem que precisemos programar explicitamente o que é uma partida boa ou ruim.

O modelo desenvolvido serve como um modelo simplista para problemas mais sérios, como filas de atendimento, reações químicas em cadeia ou navegação em grafos, onde estados absorventes e transições probabilísticas definem o comportamento do sistema.

7. Referências

- <https://www.networkpages.nl/mr-markov-playing-snakes-and-ladders/>
- <https://ijmttjournal.org/public/assets/volume-67/issue-1/IJMTT-V67I1P507.pdf>
- <https://www.scribd.com/doc/287826473/The-Mathematical-Analysis-of-Snakes-and-Ladders>
- <https://freerangestats.info/blog/2024/08/10/snakes-and-ladders>

- <https://scikit-learn.org/stable/modules/decomposition.html#principal-component-analysis-pca>
- <https://scikit-learn.org/stable/modules/clustering.html#k-means>

8. Colab do Projeto

<https://colab.research.google.com/drive/1oUcDY2GF0qITLJaK81bEpbp0mZsp4qSN?usp=sharing>